

Práctica 2

Tipología y ciclo de vida de los datos

**Máster Universitario en Ciencia de Datos –
UOC**

Integrantes del grupo:

Daniel Francisco Moreno Linares

Victor Benito Buendía

1. Descripción del dataset

El dataset utilizado es el “**Pima Indians Diabetes Database**”, disponible públicamente en Kaggle.

Enlace directo al dataset:

<https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>

Fuente original: National Institute of Diabetes and Digestive and Kidney Diseases (EE.UU.).

Descripción:

Este dataset contiene información diagnóstica de **768 mujeres** de ascendencia indígena Pima (mayores de 21 años) residentes cerca de Phoenix, Arizona. El objetivo es predecir si una paciente tiene o no diabetes tipo 2 basándose en ciertas medidas diagnósticas.

Pregunta de investigación / Problema a resolver:

¿Qué factores clínicos y antropométricos son los más relevantes para predecir la presencia de diabetes tipo 2, y es posible construir un modelo predictivo preciso?

Este análisis es relevante a nivel global en el ámbito de la salud pública, ya que la diabetes es una de las principales enfermedades crónicas del mundo.

Variables del dataset (9 variables):

Variable	Tipo	Descripción
Pregnancies	Numérica entera	Número de embarazos
Glucose	Numérica continua	Nivel de glucosa en plasma (mg/dL)
BloodPressure	Numérica continua	Presión arterial diastólica (mm Hg)
SkinThickness	Numérica continua	Grosor del pliegue cutáneo tríceps (mm)
Insulin	Numérica continua	Insulina en suero a las 2h (μU/mL)
BMI	Numérica continua	Índice de Masa Corporal (kg/m ²)
DiabetesPedigreeFunction	Numérica continua	Función de pedigrí de diabetes
Age	Numérica entera	Edad en años
Outcome	Binaria (Objetivo)	0 = No diabético, 1 = Diabético

Tamaño inicial: 768 registros × 9 variables.

2. Integración y selección de los datos

Se utilizó principalmente el dataset original descargado de Kaggle. Para enriquecer el análisis y cumplir mejor con los requisitos de la práctica, se realizaron las siguientes acciones de integración y creación de variables:

- Creación de variables categóricas derivadas: AgeGroup, BMICategory, GlucoseCategory.
- Se mantuvo el dataset completo (768 registros) tras la limpieza, sin necesidad de integración externa adicional.
- 8 variables predictoras
- 1 variable objetivo (Outcome)

Distribución de variables categóricas creadas:

Categoría	Valores y frecuencias
AgeGroup	Young: 417 (54.3%) Adult: 270 (35.2%) Senior: 81 (10.5%)
BMI_Category	Obese: 476 (62%) Overweight: 180 (23.4%) Normal: 108 (14.1%) Underweight: 4 (0.5%)
Glucose_Category	Diabetes: 297 (38.7%) Prediabetes: 279 (36.3%) Normal: 181 (23.6%) Hypoglycemia: 11 (1.4%)

El análisis estadístico del dataset lo podemos ver con la función describe() de python.

```
===== DESCRIPTIVE STATISTICS =====
      Pregnancies  Glucose  BloodPressure  SkinThickness  Insulin   BMI  DiabetesPedigreeFunction  Age  Outcome
count    768.000000    768.000000    768.000000    768.000000    768.000000    768.000000    768.000000    768.000000    768.000000
mean      3.845052    120.894531     69.105469     20.536458     79.799479     31.992578      0.471876     33.240885      0.348958
std       3.369578     31.972618     19.355807     15.952218    115.244002     7.884160      0.331329     11.760232     0.476951
min       0.000000     0.000000     0.000000     0.000000     0.000000     0.000000      0.078000     21.000000     0.000000
25%       1.000000     99.000000     62.000000     0.000000     0.000000     27.300000      0.243750     24.000000     0.000000
50%       3.000000    117.000000     72.000000     23.000000     30.500000     32.000000      0.372500     29.000000     0.000000
75%       6.000000    140.250000     80.000000     32.000000    127.250000     36.600000      0.626250     41.000000     1.000000
max      17.000000    199.000000    122.000000     99.000000    846.000000     67.100000      2.420000     81.000000     1.000000
```

En este reporte podemos observar varias cosas importantes, como el hecho de que el valor medio de la glucosa es de 120.8 y su pico es de 199, esto nos indica que los niveles promedio están por encima del rango normal, lo cual sugiere presencia considerable de pacientes con riesgo diabético. Además, un valor de glucosa igual a 0 es fisiológicamente imposible, indicando datos faltantes codificados como cero o valores erróneos, esto también se presenta en variables como BloodPressure, Insulin y BMI.

3. Limpieza de los datos

3.1. Gestión de valores faltantes y ceros

No hay explícitamente valores faltantes en el dataset pero como fue mencionado, hay valores atípicos físicamente imposibles como que hayan niveles de BMI en 0. Aquellas columnas en que estos valores son irreales se reemplazan los valores con 0 por "NaN" con la función `replace_invalid_zeros()` creada en el preprocesado.

Luego se imputan los datos para que esos valores faltantes sean reemplazados con valores estándar que podamos utilizar en el análisis. Esto se realiza con la función creada `impute_missing_values()` y usando la librería `SimpleImputer` de `sklearn`.

Variable	Ceros (datos faltantes)	% del total	Acción
Glucose	5	0.65%	Reemplazar por NaN Contabilizar mediana
BloodPressure	35	4.56%	Reemplazar por NaN Contabilizar mediana
SkinThickness	227	29.56%	Reemplazar por NaN Contabilizar mediana
Insulin	374	48.70%	Reemplazar por NaN Contabilizar mediana
BMI	11	1.43%	Reemplazar por NaN Contabilizar mediana

3.2. Tipos de datos


Vemos el análisis descriptivo del dataset resultado de la función `info()` de `python`.

Tipo	Variables
float64 (numéricas continuas)	Pregnancies, Glucose, BloodPressure, SkinThickness, Insulin, BMI, DiabetesPedigreeFunction, Age, Outcome
category	AgeGroup, BMI_Category, Glucose_Category


Podemos ver que no hay variables que no sean tipo número, por lo cual se enriquece el dataset con la creación de 3 variables categóricas.

3.3. Valores extremos

Para este caso no se han eliminado valores extremos pero si se han analizado mediante el uso de Boxplots que podemos ver a continuación:




Podemos observar que el 50% de la muestra está aproximadamente en 29 años como indicó en su momento la función describe(), el valor atípico de edad es 81 y la mayoría de datos se agrupan entre 24 y 41 años.




En cuanto a la presión sanguínea, vemos que el promedio está aproximadamente en 69, tiene valores outliers antes y después del grupo representativo, y además se puede observar que los valores atípicos imposibles de 0 ya no están presentes


gracias al tratamiento que se hizo en el preprocesado.




Para el índice de masa corporal también podemos observar en el gráfico el tratamiento de ceros realizado, los valores típicos de BMI si están en el rango esperado y los outliers presentes pueden aportar información al modelo.



Luego del tratamiento de ceros podemos observar que la glucosa no presenta valores fuera del rango del 50% de los datos, esto quiere decir que luego del tratamiento todos los datos quedaron dentro del rango esperado para alimentar el modelo.



En el caso de la insulina vemos un promedio de 80 aproximadamente pero a diferencia de los otros gráficos, muchos de los datos quedan fuera del 50% representados en el promedio, este comportamiento es una asimetría positiva que en este caso nos dice que los datos de esta variable son asimétricos y muy dispersos, en este caso si valdría la pena eliminar outliers pero dado que nuestro dataset es relativamente pequeño para entrenar modelos supervisados o no supervisados, se decide conservar los valores y observar el comportamiento del modelo.




Acá podemos ver que médicamente hablando hay valores atípicos en ambos extremos, con la salvedad de que aquellos que eran ceros fueron tratados en el preprocesamiento y ya no se observan en la gráfica, sin embargo podemos ver

valores de 99 mm de grosor de piel lo cual es claramente un valor irreal que no fue tenido en cuenta hasta este punto.

3.4. Otros métodos

Se analizó también el resultado de la matriz de correlación entre las variables numéricas del dataset, esto con el fin de observar la fuerza y dirección de la relación lineal entre cada par de variables, ayudando a identificar patrones, dependencias o redundancias en un conjunto de datos.



Podemos observar que los mayores pesos de correlación entre las variables se observan entre la edad y los embarazos, los niveles de glucosa y los resultados, el índice de masa corporal y el grosor de la piel.

Esas 3 correlaciones son las que agregarán más peso o darán más información al modelo para poder predecir un resultado satisfactorio.

4. Análisis de los datos

La hipótesis por resolver para nuestro caso es poder decir **sí** a partir de las variables biomédicas presentes en nuestro dataset, es posible predecir si una persona va a padecer de diabetes o no. Para ello y a solicitud del enunciado, aplicamos dos modelos de datos.

4.1. Modelos aplicados

Regresión Logística:

La regresión logística es un algoritmo de clasificación binaria que predice probabilidades usando una función sigmoide, esto significa que el modelo combina las variables de entrada para calcular la probabilidad de diabetes.

En el código se entrena y calcula este modelo solo con las variables numéricas y utilizando como variable objetivo la columna "Outcome", luego se entrena el modelo y se genera un reporte por consola de los resultados obtenidos.

KMeans:

Este es un modelo no supervisado, lo que significa que intenta encontrar patrones ocultos en el conjunto de datos de manera automática, para este caso se usó KMeans de la librería sklearn de Python. Como nuestro objetivo es saber si un paciente tiene diabetes o no, se configuran 2 clusters para el modelo y el algoritmo calcula las distancias hacia los centroides para clasificarlos.

Resultados esperados:

Regresión Logística:

Podemos observar que el modelo tiene una precisión global del 75%, es decir que acierta 3 de cada 4 pacientes correctamente. También podemos notar que es más preciso para detectar cuando alguien no tiene diabetes (80%) que cuando si tiene (67%). El recall nos indica que predijo correctamente un 83% de las veces cuando un paciente no tenía diabetes pero predijo correctamente solo un 62% de las veces cuando si tenía diabetes.

Resultados del modelo (conjunto de test, 154 muestras):

Clase	Precision	Recall	F1-Score	Support
No diabético (0)	0.80	0.83	0.81	99
Diabético (1)	0.67	0.62	0.64	55
Accuracy			0.75	154
Macro avg	0.73	0.72	0.73	154
Weighted avg	0.75	0.75	0.75	154

Con estos resultados vemos que el modelo tiene más dificultad detectando pacientes diabéticos lo cual tiene sentido ya que los casos positivos suelen ser más complejos y se evidencia un cierto desbalance en el dataset.

KMeans:

Para este modelo obtenemos la siguiente métrica de resultado:

```
===== UNSUPERVISED MODEL =====  
Silhouette Score: 0.1963
```

Esto nos mide qué tan bien separados están los clusters, un valor cercano a 1 nos indica una separación perfecta de los clusters, un valor cercano a 0 indica que los clusters están mezclados y un valor negativo indica que el ejercicio es incorrecto. Para este caso en concreto, este valor indica que hay una separación débil, los clusters están poco definidos y hay un alto solapamiento entre grupos, esto indica que los pacientes diabéticos y no diabéticos comparten características similares en varias variables biomédicas. Con esto podemos concluir que el modelo KMeans no logró identificar grupos claramente diferenciados entre pacientes diabéticos y no diabéticos.

4.2. Prueba de hipótesis

H0

Los niveles de glucosa son iguales entre pacientes diabéticos y no diabéticos.

H1

Los niveles de glucosa son diferentes.

Con esta hipótesis en mente, se configuró una prueba de hipótesis por código en el script usando la librería `scipy.stats` de Python.

Primero se verificaron los supuestos con Shapiro-Wilk, obteniendo un valor $p < 0.05$, lo que indica que no hay normalidad.

Grupo	Estadístico W	p-valor	Conclusión
Diabéticos (n=268)	0.9738	0.0001	No normal ($p < 0.05$)
No diabéticos (n=500)	0.9749	< 0.0001	No normal ($p < 0.05$)

Luego se utilizó Levene para evaluar la homocedasticidad (u homogeneidad de varianzas) que nos dio un valor de $p < 0.05$, lo que indica que no hay igualdad de varianzas.

Estadístico F	p-valor	Conclusión
24.03	< 0.0001	Varianzas no homogéneas ($p < 0.05$)


Por último se aplicó Mann-Whitney U, una prueba no paramétrica que nos arrojó el mismo resultado, $p < 0.05$.

Estadístico U	p-valor	Conclusión
106065.5	< 0.000001	Se rechaza H_0 ($p < 0.05$)

```
===== HYPOTHESIS TESTING =====
Shapiro diabetic p-value: 0.0001
Shapiro non-diabetic p-value: 0.0000
Levene p-value: 0.0000
Mann-Whitney U p-value: 0.0000
There is a statistically significant difference.
```

Con estos resultados podemos concluir que existe diferencia estadísticamente significativa en glucosa entre ambos grupos. Por lo tanto se rechaza nuestra H_0 y se acepta nuestro H_1 .

5. Representación de los resultados



Los histogramas muestran que Glucose, BMI y Age presentan distribuciones notablemente diferentes entre ambos grupos, confirmando su poder discriminativo observado en el modelo supervisado.

Durante las respuestas de apartados de la práctica se han adjuntado otras visualizaciones como tablas o gráficas para acompañar las respuestas.

6. Resolución del problema

Conclusiones principales:

El análisis realizado permite responder satisfactoriamente a la pregunta de investigación planteada:

La glucosa es el factor clínico más determinante para predecir diabetes tipo 2, coeficiente 1.11 en regresión logística, diferencia de medias de 31.45 mg/dL entre grupos, correlación 0.49 con Outcome.

El modelo de regresión logística alcanza una exactitud del 75%, con una precisión del 80% para pacientes sanos y del 67% para diabéticos. Es un resultado razonable para un clasificador lineal sobre datos clínicos con importante variabilidad.

El K-Means con $k=2$ identifica dos grupos naturales que se corresponden en un 55.6% y 82.5% respectivamente con las clases reales del problema, sin haber usado la etiqueta. Esto valida la estructura subyacente del dataset.

El test de Mann-Whitney U confirma con $p < 0.000001$ que los niveles de glucosa son significativamente diferentes entre diabéticos y no diabéticos.

Las variables más relevantes para la predicción son, en orden: Glucose, BMI, Age y Pregnancies, lo que es coherente con la evidencia médica sobre factores de riesgo de diabetes tipo 2.

La imputación por mediana fue adecuada para gestionar los valores faltantes, y permitió mantener el dataset completo sin pérdida de registros.

Limitaciones:

El dataset está limitado a mujeres de una población específica que es Pima Indians, lo que limita la generalización de los modelos a otras poblaciones.

Un modelo más complejo como Random Forest o XGBoost tal vez alcanzaría mejor rendimiento.

Contribuciones	Firma
Investigación previa	Victor Benito Buendia
Redacción de respuestas	Daniel Francisco Moreno Linares Victor Benito Buendia
Desarrollo del código	Daniel Francisco Moreno Linares
Participación del video	Daniel Francisco Moreno Linares Victor Benito Buendia

Repositorio github:

<https://github.com/dmorenoli/Tipolog-a-y-Ciclo-de-Vida-de-los-Datos-PRACTICA-2>

Enlace video:

<https://drive.google.com/file/d/13ISE378laQN6ORT6cuF5U9dSHN9JL83Y/view?usp=sharing>